Universidade Federal do Mato Grosso do Sul

Curso de Bacharelado em Engenharia Elétrica - FAENG

Sistema 6G – Pré-Distorsor Digital sintetizado em FPGA com uso de Inteligência Artificial: um estudo do modelo VARMAX

Prof. Dr. Guilherme Augusto Defalque
Pedro Arfux
Prof. Dr. Bruno Sereni
Prof. Dr. Edson Batista

Roteiro

- Objetivos;
- Séries Temporais;
- Como as Séries Temporais se encaixam em nosso problema?
- VARMAX;
- Dados;
- Análise dos Dados;
- Sintetização do modelo de PA com VARMAX;
- Resultados iniciais;
- Melhoria nos resultados iniciais;
- Próximos passos.

Objetivos

- Compreender como o problema se encaixa em um problema de séries temporais;
- Entender o funcionamento do VARMAX;
- Compreender como VARXMAX pode ser uma solução em termos de custo/benefício.

Séries Temporais

- Uma série temporal é um conjunto de observações ordenadas no tempo, coletadas em intervalos regulares (diários, mensais, anuais, por segundo, etc);

Uma série temporal Y_t costuma ser vista como a soma de quatro componentes:

$$Y_t = T_t + S_t + C_t + E_t$$

onde:

Componente	Descrição	Exemplo
Tendência (T_t)	Movimento de longo prazo (aumento ou queda)	Crescimento populacional
Sazonalidade (S_t)	Padrão que se repete em intervalos fixos	Vendas aumentam todo dezembro
Ciclo (C_t)	Flutuações de médio prazo sem periodicidade fixa	Crises econômicas
Erro (E_t)	Ruído aleatório	Variações imprevisíveis

Séries Temporais

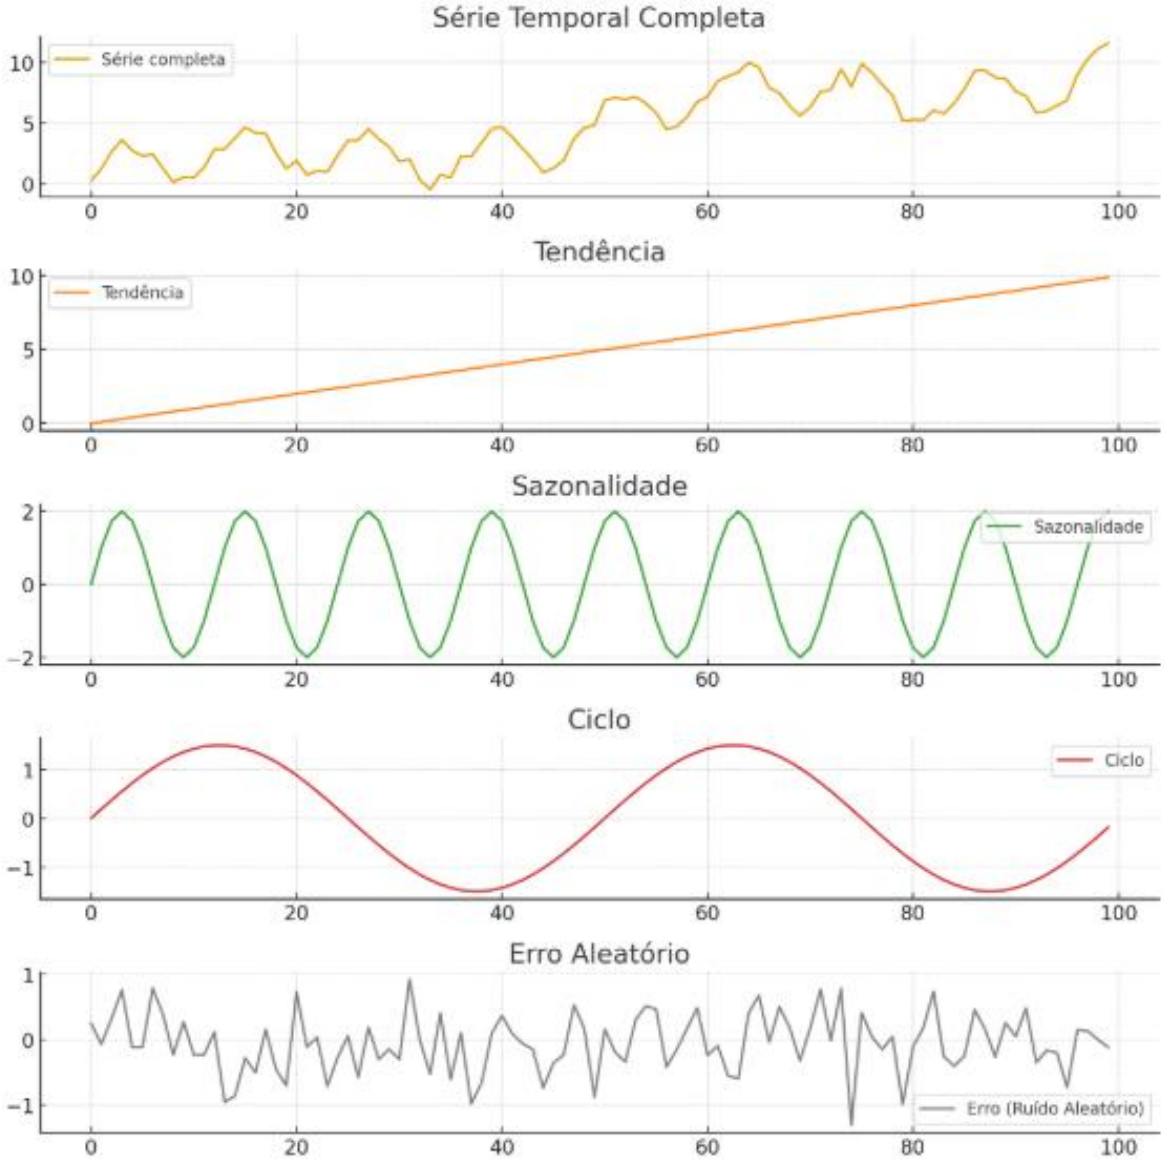

Como as Séries Temporais se encaixam em nosso problema?

- Nos transmissores de rádio, celular, Wi-Fi, etc., o **amplificador de potência (PA)** é o último estágio antes da antena.
- Ele tem a função de **ampliar o sinal**, mas apresenta **não linearidades** — especialmente quando operando próximo da saturação (onde a eficiência é maior).
- Essas não linearidades causam:
  - **Distorção do sinal** (degrada a modulação e a EVM);
  - **Espalhamento espectral** (interferência em canais adjacentes);
  - **Perda de eficiência energética** se o PA for mantido longe da saturação para evitar distorção.

Como as Séries Temporais se encaixam em nosso problema?

- A **pré-distorção digital** tenta *corrigir antecipadamente* essas distorções.
  1. Um **modelo matemático** (ou de aprendizado) imita o comportamento do PA.
  2. O sistema aplica **a distorção inversa** ao sinal de entrada — antes de enviá-lo ao PA.
  3. Após passar pelo PA real (não linear), o resultado final **volta a ser linearizado**.

Como as Séries Temporais se encaixam em nosso problema?

- O comportamento do PA não depende apenas do valor atual da amostra — ele também sofre de **memória** (dependência temporal).
  Por exemplo:
  - Efeitos térmicos;
  - Capacitâncias internas;
  - Fenômenos de histerese;
  - Dinâmica de bias e envelope do sinal.
- Isso significa que **a saída atual depende de entradas passadas** — exatamente a definição de **série temporal**.

Tipos e Modelos de Séries Temporais

Tipo	Descrição	Exemplo
Univariada	Uma variável ao longo do tempo	Temperatura diária
Multivariada	Várias variáveis medidas simultaneamente	Temperatura + Umidade + Pressão
Com entrada exógena	Série com influência externa	Consumo elétrico afetado pela temperatura

Tipo de modelo	Exemplo	Características
Estatísticos clássicos	AR, MA, ARIMA, VAR, VARMAX	Lineares, interpretáveis
Baseados em aprendizado	RNN, LSTM, GRU, Transformers	Não lineares, flexíveis
Híbridos	ARIMA + LSTM	Combina linear e não linear

Para criar modelos que caracterizem as séries temporais, precisamos de:

- Dados;
- Análise dos Dados;
- Sintetizar os Modelos;
- Validar e Testar os Modelos;
  - **Modelos mais simples**: performance tende a ser menor, mas implementação prática simples;
  - **Modelos mais robustos:** performance tende a ser alta, mas implementação prática é custosa;
- **DESAFIO:** qual melhor modelo? **Inciamos com modelos mais simples.**

Vetor AutoRegressivo de Média Móvel com Regressores Exógenos (VARMAX)

- **V+Ar+MA+X**:
  - **V:** Vetor;
  - **AR:** AutoRegressivo;
  - **MA:** Média Móvel;
  - **X** (eXogenous variables: ou variáveis exógenas);
- **AR**: modelo autoregressivo (AR) diz que o valor atual depende dos valores passados da mesma variável.

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$$

- c é constante, sigmas (pesos) das Lags (defasagens) de yt; E (ruído, parte não previsível);

Vetor AutoRegressivo de Média Móvel com Regressores Exógenos (VARMAX)

- **V+Ar+MA+X**:
  - **V:** Vetor;
  - **AR:** AutoRegressivo;
  - **MA:** Média Móvel;
  - **X** (eXogenous variáveis: ou variáveis exógenas);
- **MA**: incorpora a dependência entre uma série temporal e erros de previsões passados (os choques ou inovações).

$$y_t = c + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \varepsilon_t$$

- O foco aqui não é nos valores passados de y, mas nos choques (erros) que ocorreram antes;

Vetor AutoRegressivo de Média Móvel com Regressores Exógenos (VARMAX)

- **V+Ar+MA+X**:
  - **V:** Vetor;
  - **AR:** AutoRegressivo;
  - **MA:** Média Móvel;
  - **X** (eXogenous variáveis: ou variáveis exógenas);
- **VARMA**: cada variável na sua série temporal é modelada como uma função linear dos seus próprios valores passados e dos valores passados de todas as outras variáveis do sistema.

$$\begin{cases} y_{1,t} = c_1 + a_{11}y_{1,t-1} + a_{12}y_{2,t-1} + \varepsilon_{1,t} \\ y_{2,t} = c_2 + a_{21}y_{1,t-1} + a_{22}y_{2,t-1} + \varepsilon_{2,t} \end{cases}$$

- C1 e C2 são constantes; nos “as” são coeficientes do modelo e os “Es” são os erros.

Vetor AutoRegressivo de Média Móvel com Regressores Exógenos (VARMAX)

- **V+Ar+MA+X**:
  - **V:** Vetor;
  - **AR:** AutoRegressivo;
  - **MA:** Média Móvel;
  - **X** (eXogenous variáveis: ou variáveis exógenas);
- **VAR + X**: amplia o VAR tradicional adicionando termos que representam influências exógenas (parâmetros que influenciam nas variávies endógenas).

$$y_t = c + A_1 y_{t-1} + A_2 y_{t-2} + \cdots + A_p y_{t-p} + B x_t + \varepsilon_t$$

onde:

- y_t: vetor de variáveis **endógenas**
- x_t: vetor de variáveis **exógenas**
- A_i: matrizes de coeficientes autorregressivos
- B: matriz que mostra o quanto as exógenas influenciam o sistema
- ε_t: ruído (erros)

Vetor AutoRegressivo de Média Móvel com Regressores Exógenos (VARMAX)

- **VARMAX:**

$$Y_t = c + \sum_{i=1}^{p} A_i Y_{t-i} + \sum_{j=1}^{s} B_j X_{t-j} + \sum_{k=1}^{q} M_k \varepsilon_{t-k} + \varepsilon_t$$

onde:

- Y_t: vetor das **variáveis endógenas** (aquilo que o modelo tenta prever);
- X_t: vetor das **variáveis exógenas** (entradas externas);
- ε_t: vetor de erros (ou "ruído branco");
- p: número de **lags endógenos** (quantos Y_{t-i} entram);
- s: número de **lags exógenos** (quantos X_{t-j} entram);
- q: número de **lags dos erros** (parte MA — média móvel).

Vetor AutoRegressivo de Média Móvel com Regressores Exógenos (VARMAX)

- **Como o VARMAX escolhe seus coeficientes?**
  - O método mais utilizado é o método dos mínimos quadrados ordinários (OLS);
  - Escolhe os coeficientes que minimizam a soma dos quadrados dos erros (Et);

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

Soma dos erros quadráticos:

$$\mathrm{SSE} = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

Deriva-se SSE em relação a B0 e B1:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Vetor AutoRegressivo de Média Móvel com Regressores Exógenos (VARMAX)

- **Requisitos: série temporal estacionária.**
  - **Média constante ao longo do tempo;**
  - **Variância constante ao longo do tempo;**
  - **Aucovariância depende apenas da defasagem (lag):**
    - Significa que o passado de Yt tem influência no presente;
  - **Ausência de multicolinearidade severa entre as variáveis exógenas:**
    - Se, por exemplo X[k-1] e X[k-2] influenciam igualmente em Y[k].
- O comportamente estático da série não muda com o tempo;
- Testes estatísticos podem nos dar probabilidade de uma série ser estacionária ou não;
  - Kpss;
  - DF (Dickey Fuller);

Dados

- Dados de um PA real foram adquiridos em: https://www.mathworks.com/help/comm/ug/data-preparation-for-neural-network-digital-predistortion-design.html
- **Esse exemplo de dados usa 5G-like OFDM (Multiplexação por divisão de frequência ortogal) WAVEFORM:**
  - **Largura de banda: 100 MHz;**
  - **Onde cada subportadora possui 16-QAM símbolo;**
  - **6 símbolos OFDM sucessivos são gerados;**

Dados dos dados

- ~48 mil linhas e 4 colunas;

	Xreal	Ximg	Yreal	Yimg
0	1.137499	0.082685	26.244322	1.471061
1	1.117805	0.225745	25.818823	4.754794
2	1.078412	0.365120	24.978243	8.000349
3	1.020086	0.498130	23.716368	11.057279
4	0.944010	0.622210	22.005617	13.972568
...	...	...	...	...
48378	0.852823	-0.726484	19.257505	-17.156517
48379	0.943207	-0.614669	21.376001	-14.639256
48380	1.018323	-0.492173	23.199469	-11.852586
48381	1.076463	-0.360888	24.612610	-8.843221
48382	1.116198	-0.222894	25.594149	-5.662292

48383 rows × 4 columns

Dados: análise da magnitude

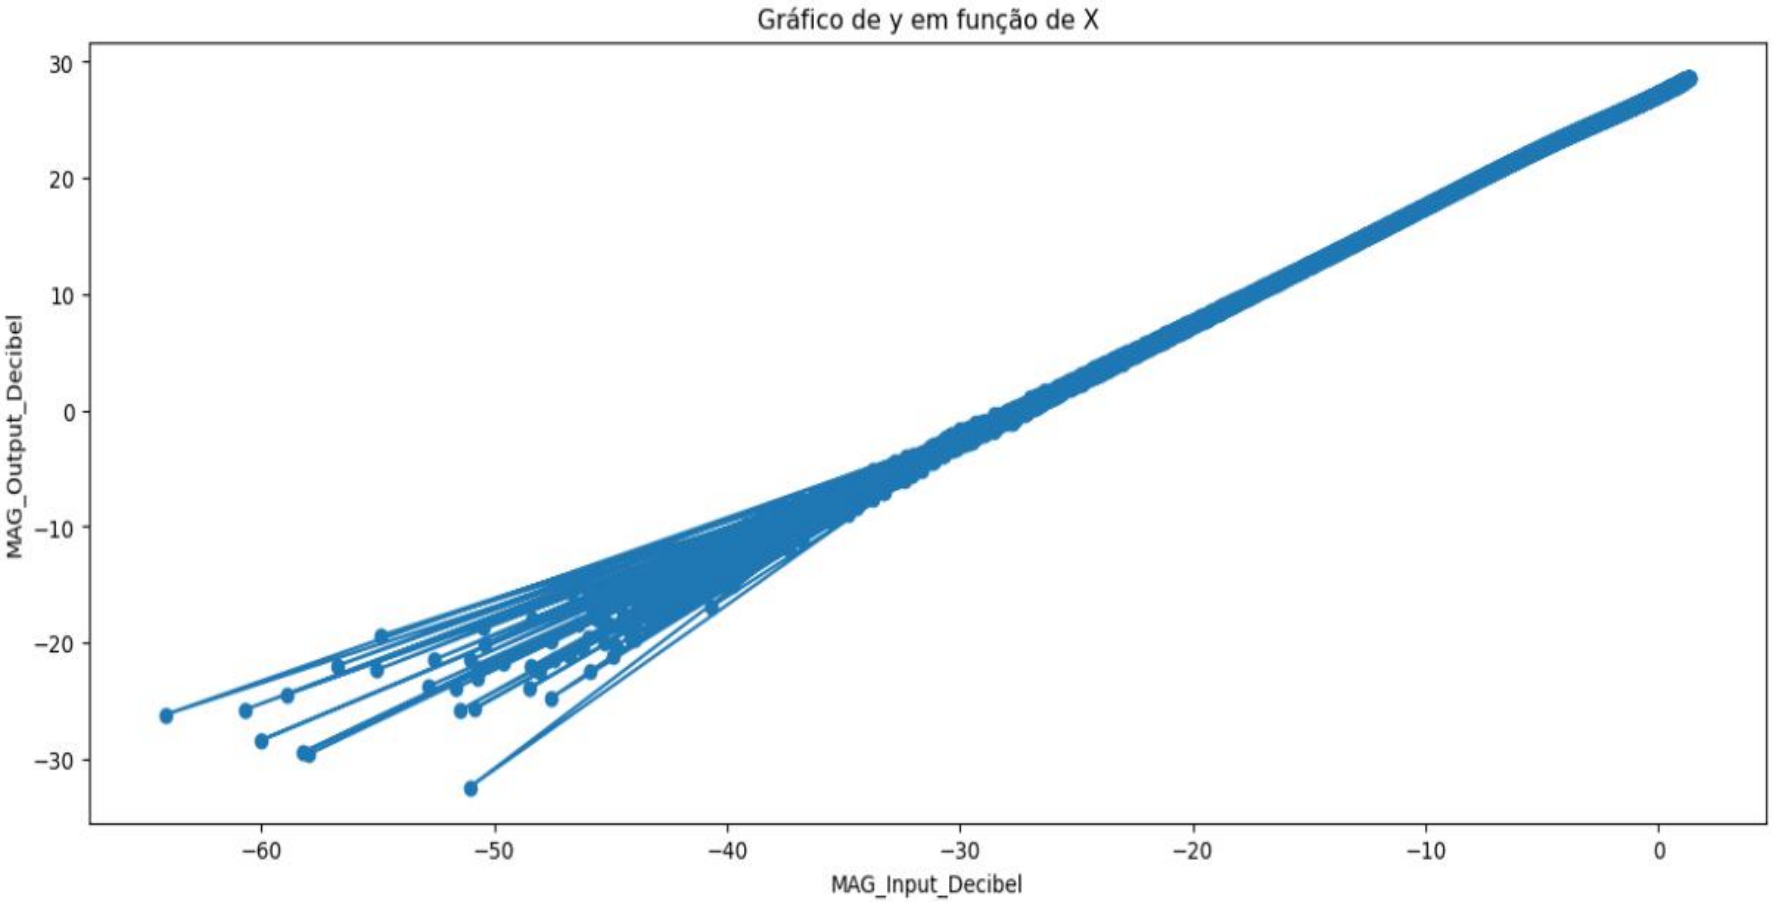

Dados: análise de normalidade

- Modelos mais simples tendem a ter melhor performance em seu ajuste (e melhor overfitting) se temos dados normais;

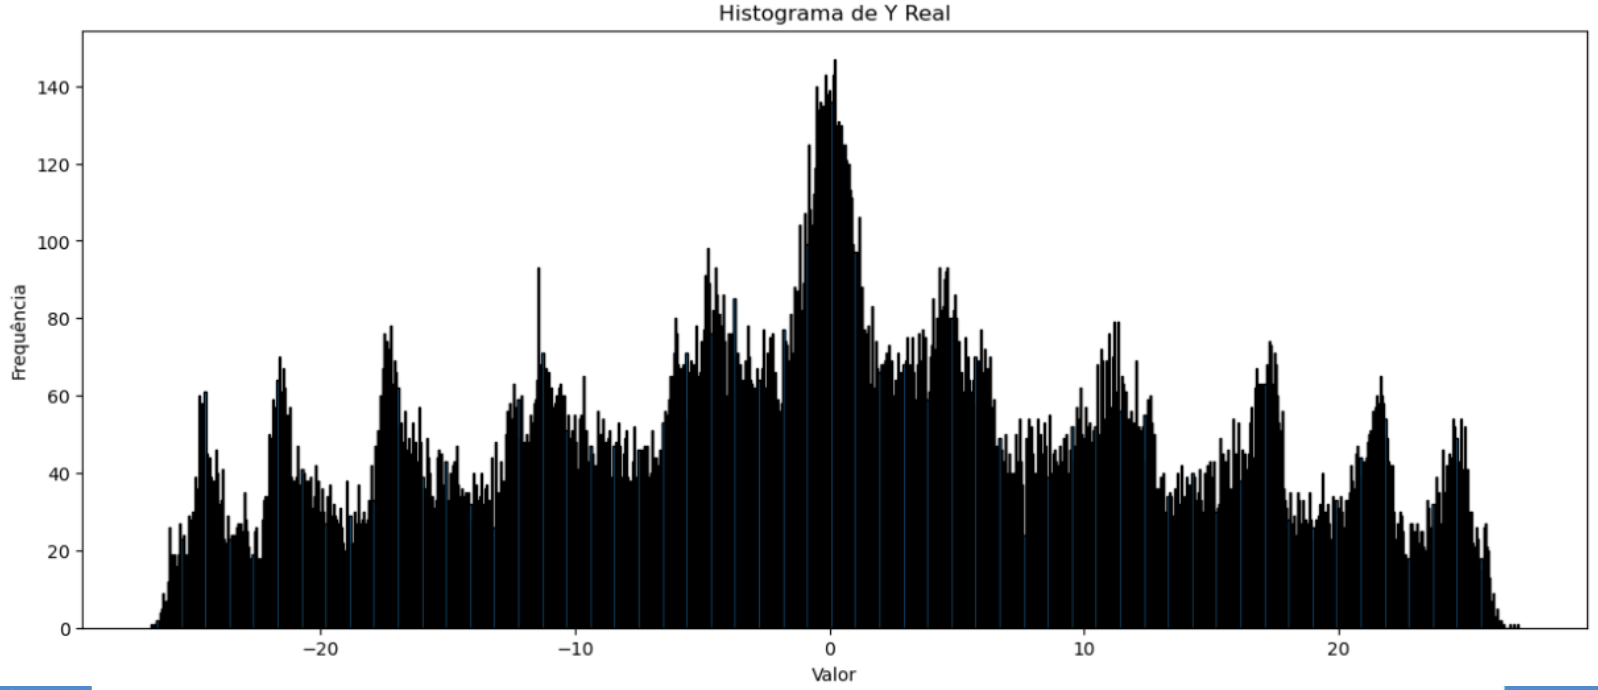

Dados: análise de normalidade

- Teste de Shapiro-Wild foi aplicado em todas as variáveis dependentes e independentes: nenhum deles mostrou normalidade.
- Exemplo dos resultados:
- Y(real):

```
Estatística de teste Yreal = 0.9806814866718211
p-valor Yreal= 1.7180237190579475e-59
Rejeita H0: os dados não parecem normais
```

- Y(img):

```
Estatística de teste Yreal = 0.980662526086569
p-valor Yreal= 1.6436006255628414e-59
Rejeita H0: os dados não parecem normais
```

Dados: análise da estacionalidade

- Teste KPSS:
- Ha: não é estacionária: estatística do teste > valor crítico;
- H0 = é estacionária: estatística do teste <= valor crítico;
- **Yreal**:

```
Estatística do teste:  0.0016847730360583302
p_value do teste:  0.1
Número de lags:  109
Valores Críticos:
10% 0.347
5% 0.463
2.5% 0.574
1% 0.739
```

Dados: análise da estacionalidade

- Teste KPSS:
- Ha: não é estacionária: estatística do teste > valor crítico;
- H0 = é estacionária: estatística do teste <= valor crítico;
- **Yimg**:

```
Estatística do teste:  0.0016847730360583302
p_value do teste:  0.1
Número de lags:  109
Valores Críticos:
10% 0.347
5% 0.463
2.5% 0.574
1% 0.739
```

Dados: análise da estacionalidade

- Teste DF (Dickey Fuller):
- Ha: não é estacionária: estatística do teste > valor crítico;
- H0 = é estacionária: estatística do teste <= valor crítico;
- **Yreal**:

```
Estatística do teste:  -25.270371065821685
p_value do teste:  0.0
Valores Críticos:
1% -3.4304853263815924
5% -2.8615998114357426
10% -2.5668018356570568
```

Dados: análise da estacionalidade

- Teste DF (Dickey Fuller):
- Ha: não é estacionária: estatística do teste > valor crítico;
- H0 = é estacionária: estatística do teste <= valor crítico;
- **Yimg**:

```
Estatística do teste:  -25.44590549775064
p_value do teste:  0.0
Valores Críticos:
1% -3.4304853263815924
5% -2.8615998114357426
10% -2.5668018356570568
```

Sintetização do VARMAX para o modelo do PA

- **Divisão dos dados em Treino (60% dos dados):** utiliza 60% dos dados mais antigos do modelo para construir um modelo;
  - i = 1 … p;
  - loop:
    - Precisamos de um modelo inicial com lag = i (por exemplo com lag = 1), para em seguida validá-lo;
    - **Validação (20% dos dados):** utilizado para validar o modelo com lag = i. Armazena os resultados para comparar;
    - Sjmp loop
- **Treino + Validação (80% dos dados):** sintetiza o modelo escolhido (de acordo com as lag) para ser testado.
- **Teste (20% dos dados):** teste se o modelo construído com Treino + Validação possui performance.

Sintetização do VARMAX para o modelo do PA – validação (Lag em p)

```
Lag=1
  AIC=31594.22 | BIC=31701.81
  --- Yreal ---
     RMSE     = 13.5607
     MAE      = 11.3256
     R²       = -0.0870
     R² Ajust = -0.0871
     STD      = 13.5607
  --- Yimg ---
     RMSE     = 13.3509
     MAE      = 11.1499
     R²       = -0.0545
     R² Ajust = -0.0546
     STD      = 13.3509
```

```
Lag=2
  AIC=-172928.77 | BIC=-172788.08
  --- Yreal ---
     RMSE     = 1.0670
     MAE      = 0.8427
     R²       = 0.9933
     R² Ajust = 0.9933
     STD      = 1.0653
  --- Yimg ---
     RMSE     = 1.0824
     MAE      = 0.8410
     R²       = 0.9931
     R² Ajust = 0.9931
     STD      = 1.0823
```

```
Lag=11
  AIC=-197650.66 | BIC=-197212.03
  --- Yreal ---
     RMSE     = 0.9004
     MAE      = 0.7123
     R²       = 0.9952
     R² Ajust = 0.9952
     STD      = 0.8995
  --- Yimg ---
     RMSE     = 0.8735
     MAE      = 0.6825
     R²       = 0.9955
     R² Ajust = 0.9955
     STD      = 0.8733
```

Sintetização do VARMAX para o modelo do PA – teste (Lag em 2)

$$
\begin{aligned}
Y_{\text{real},t} = {} & \underbrace{-0.000115}_{\text{intercept}} \\
& + \underbrace{1.926283}_{L1.Yreal.Yreal} Y_{\text{real},t-1} + \underbrace{-0.226396}_{L1.Yimg.Yreal} Y_{\text{img},t-1} \\
& + \underbrace{-0.933592}_{L2.Yreal.Yreal} Y_{\text{real},t-2} + \underbrace{0.219095}_{L2.Yimg.Yreal} Y_{\text{img},t-2} \\
& + \underbrace{0.429262}_{\beta.Xreal.Yreal} X_{\text{real},t} + \underbrace{0.070241}_{\beta.Ximg.Yreal} X_{\text{img},t} + \varepsilon_{\text{real},t},
\end{aligned}
$$

$$
\begin{aligned}
Y_{\text{img},t} = {} & \underbrace{-0.000208}_{\text{intercept}} \\
& + \underbrace{0.229140}_{L1.Yreal.Yimg} Y_{\text{real},t-1} + \underbrace{1.936905}_{L1.Yimg.Yimg} Y_{\text{img},t-1} \\
& + \underbrace{-0.222614}_{L2.Yreal.Yimg} Y_{\text{real},t-2} + \underbrace{-0.944271}_{L2.Yimg.Yimg} Y_{\text{img},t-2} \\
& + \underbrace{-0.085877}_{\beta.Xreal.Yimg} X_{\text{real},t} + \underbrace{0.439614}_{\beta.Ximg.Yimg} X_{\text{img},t} + \varepsilon_{\text{img},t}.
\end{aligned}
$$

Resultados do VARMAX para o modelo do PA – teste (Lag em 2)

```
Métricas para Yreal (teste, lag=2):
  RMSE     = 1.0402
  MAE      = 0.8004
  R²       = 0.9936
  R² Ajust = 0.9936
  STD      = 1.0400

Métricas para Yimg (teste, lag=2):
  RMSE     = 1.0658
  MAE      = 0.8110
  R²       = 0.9933
  R² Ajust = 0.9933
  STD      = 1.0655
```

Resultados do VARMAX para o modelo do PA – teste (Lag em 2)

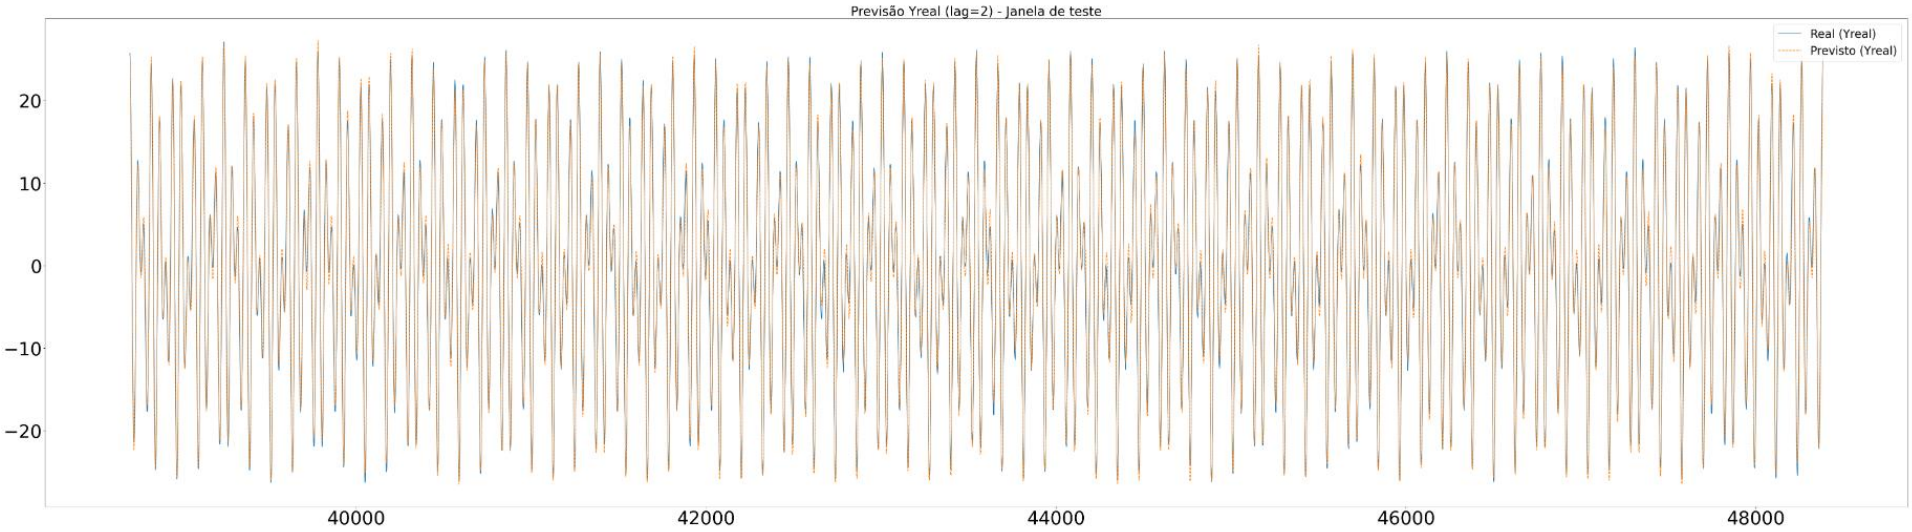

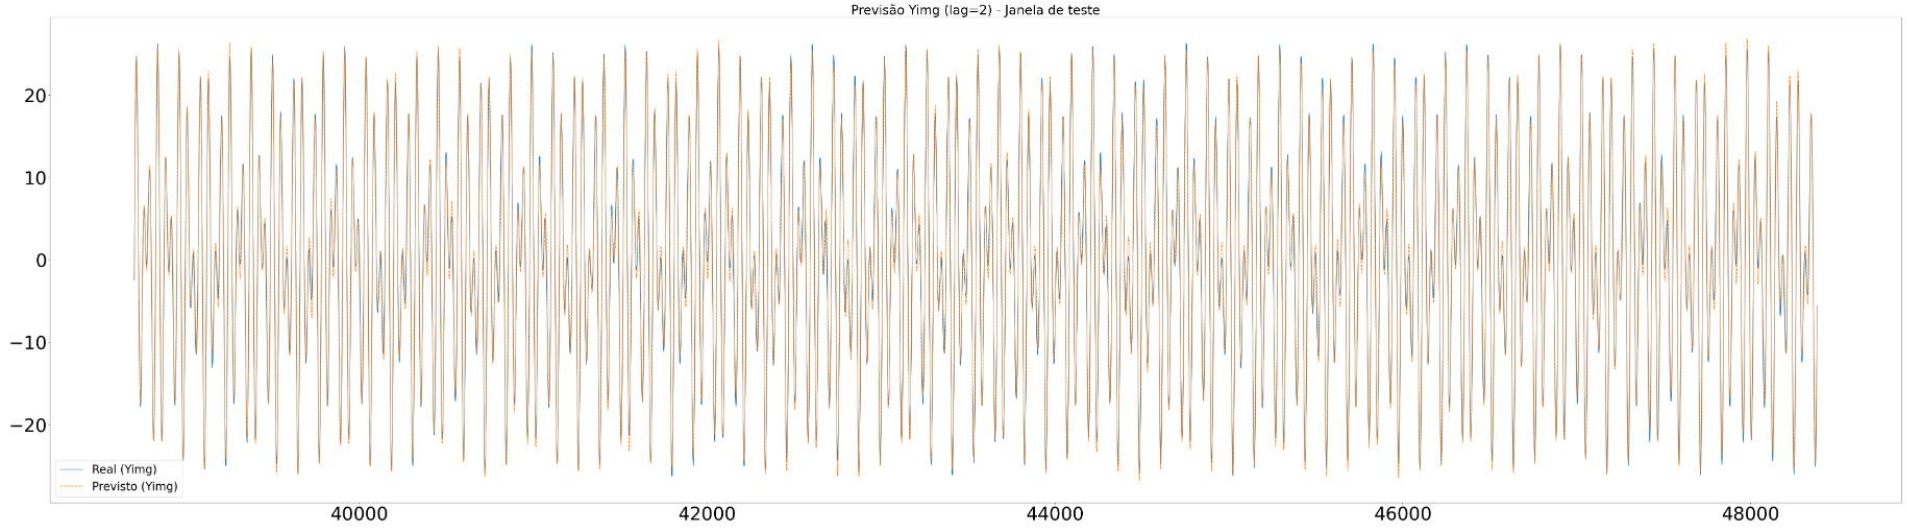

Resultados do VARMAX para o modelo do PA – teste (Lag em 2)

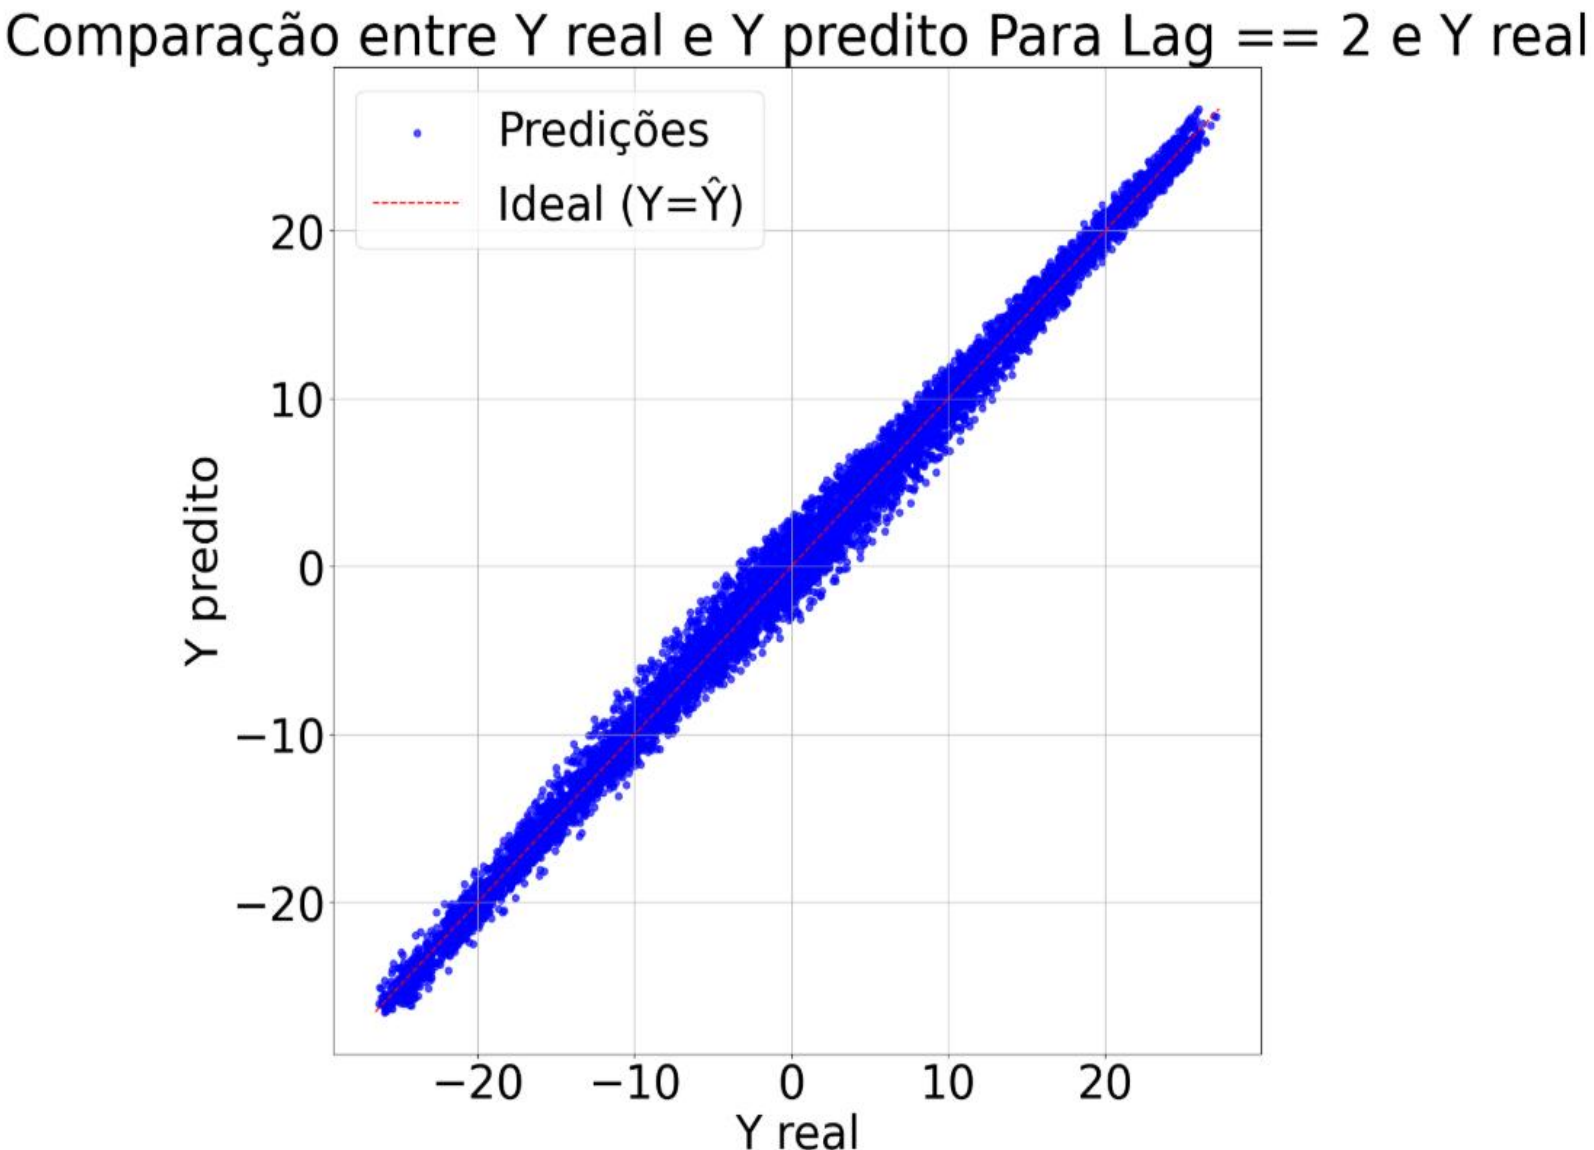

Resultados do VARMAX para o modelo do PA – teste (Lag em 2)

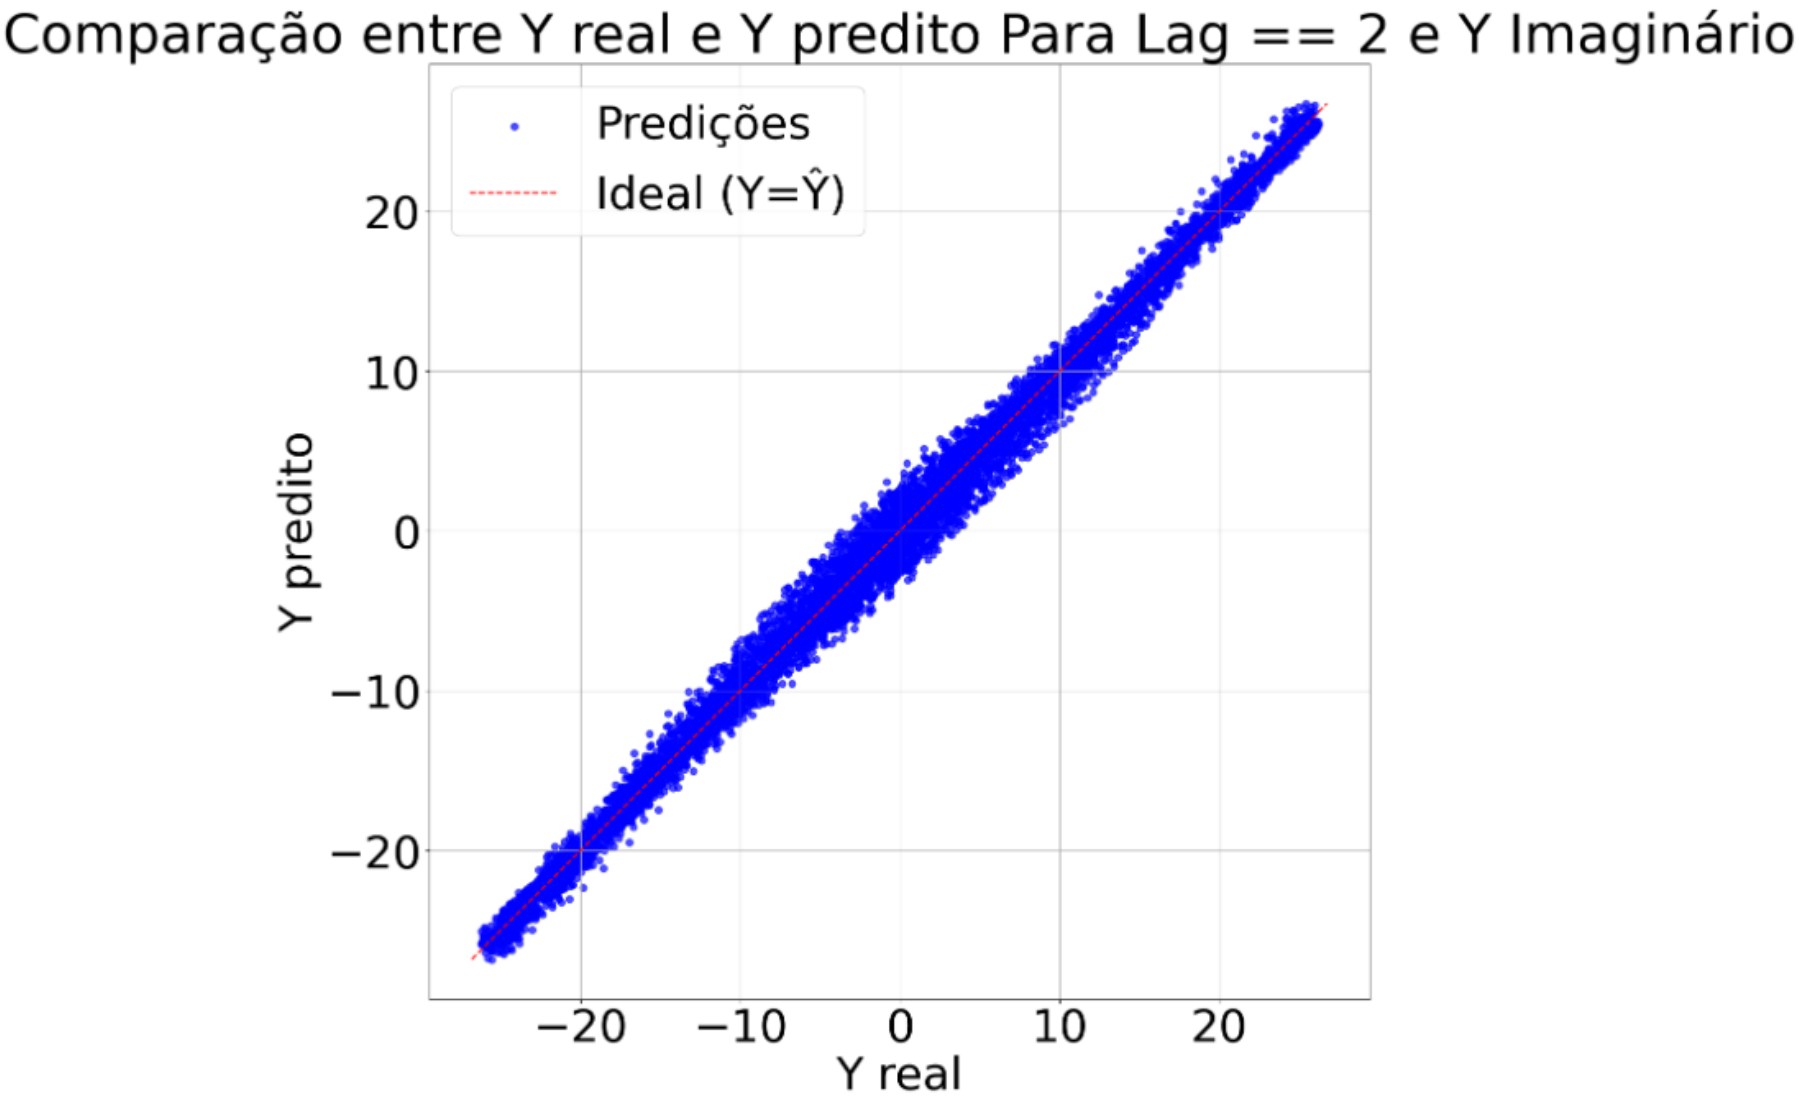

Resultados do VARMAX para o modelo do PA – magnitude (Lag em 2)

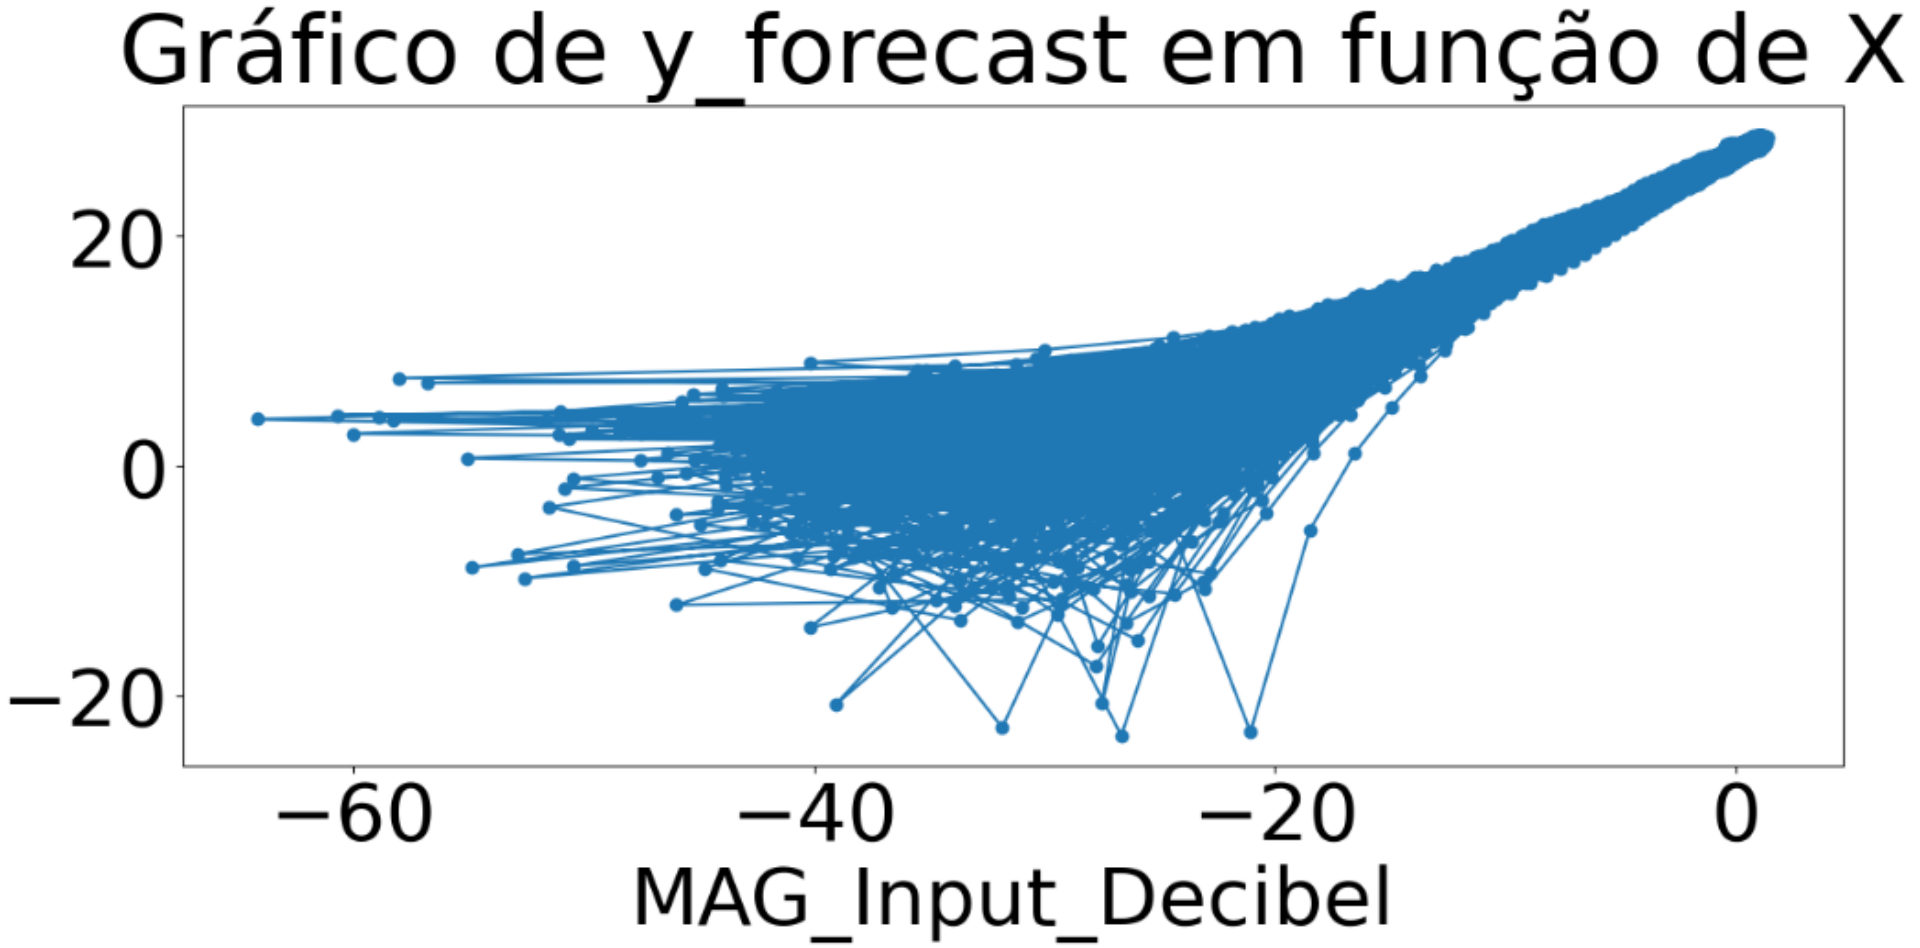

Dados: análise da magnitude

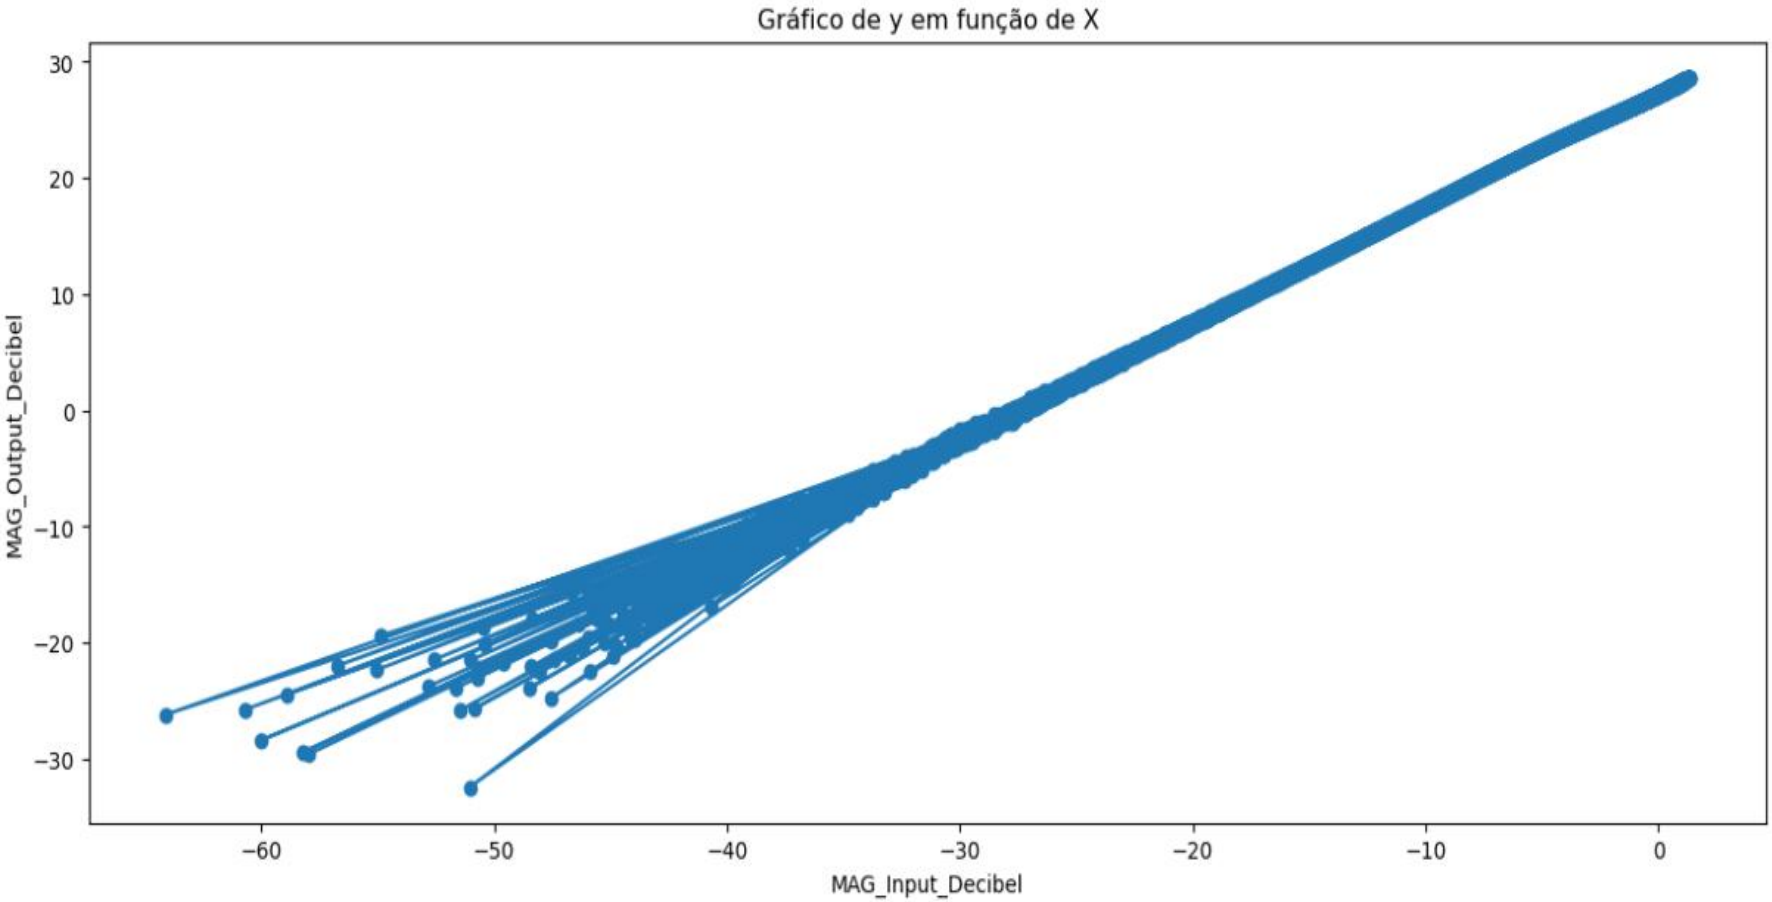

Sintetização do VARMAX: e se tivermos ordems maiores e lags para nossos Xs?

Yreal	Yimg	Xreal	Ximg	Xreal_lag1	Xreal_lag2	Ximg_lag1	Ximg_lag2	Xreal_sq	Ximg_sq	Xreal_lag1_sq	Xreal_lag2_sq	Ximg_lag1_sq	Ximg_lag2_sq
24.978243	8.000349	1.078412	0.365120	1.117805	1.137499	0.225745	0.082685	1.162973	0.133313	1.249489	1.293904	0.050961	0.006837
23.716368	11.057279	1.020086	0.498130	1.078412	1.117805	0.365120	0.225745	1.040576	0.248134	1.162973	1.249489	0.133313	0.050961
22.005617	13.972568	0.944010	0.622210	1.020086	1.078412	0.498130	0.365120	0.891154	0.387146	1.040576	1.162973	0.248134	0.133313
19.923262	16.563114	0.851759	0.734975	0.944010	1.020086	0.622210	0.498130	0.725493	0.540188	0.891154	1.040576	0.387146	0.248134
17.485760	18.874990	0.745220	0.834302	0.851759	0.944010	0.734975	0.622210	0.555352	0.696061	0.725493	0.891154	0.540188	0.387146
...	...	...	...	...	...	...	...	...	...	...	...	...	...
19.257505	-17.156517	0.852823	-0.726484	0.749079	0.634024	-0.825920	-0.911459	0.727307	0.527780	0.561119	0.401987	0.682144	0.830758
21.376001	-14.639256	0.943207	-0.614669	0.852823	0.749079	-0.726484	-0.825920	0.889640	0.377817	0.727307	0.561119	0.527780	0.682144
23.199469	-11.852586	1.018323	-0.492173	0.943207	0.852823	-0.614669	-0.726484	1.036981	0.242234	0.889640	0.727307	0.377817	0.527780
24.612610	-8.843221	1.076463	-0.360888	1.018323	0.943207	-0.492173	-0.614669	1.158774	0.130240	1.036981	0.889640	0.242234	0.377817
25.594149	-5.662292	1.116198	-0.222894	1.076463	1.018323	-0.360888	-0.492173	1.245898	0.049682	1.158774	1.036981	0.130240	0.242234

Sintetização do VARMAX para o modelo do PA com termos exógenos e lags de Segunda ordem

- **Divisão dos dados em Treino (80% dos dados):** utiliza 80% dos dados mais antigos do modelo sintetiza o modelo para ser testado.
  - Lag de p = 2.
  - Lag de s = 2 e Xs com segunda ordem.
- **Teste (20% dos dados):** teste se o modelo construído com Treino + Validação possui performance.

Resultados do VARMAX para o modelo do PA com termos exógenos e lags de Segunda ordem– teste (Lag em 2)

```
Métricas para Yreal (teste, lag=2):
  RMSE     = 0.9308
  MAE      = 0.6904
  R²       = 0.9949
  R² Ajust = 0.9949
  STD      = 0.9308

Métricas para Yimg (teste, lag=2):
  RMSE     = 0.9288
  MAE      = 0.6804
  R²       = 0.9949
  R² Ajust = 0.9949
  STD      = 0.9287
```

Resultados do VARMAX para o modelo do PA com termos exógenos e lags de Segunda ordem (magnitude)

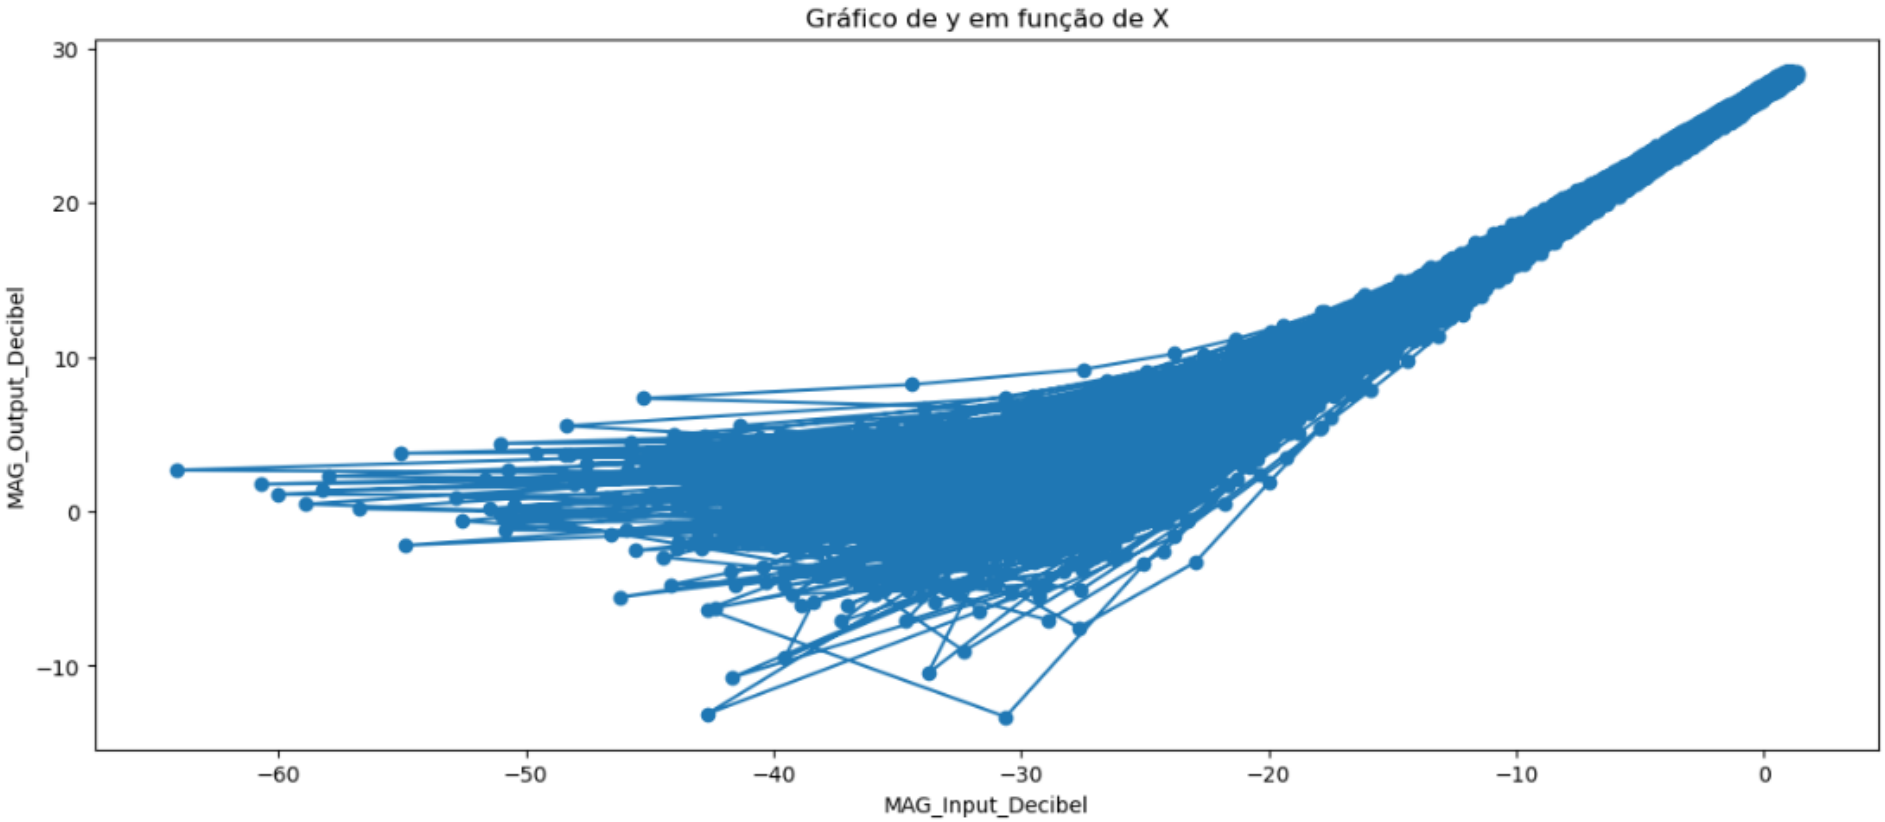

Dados: análise da magnitude

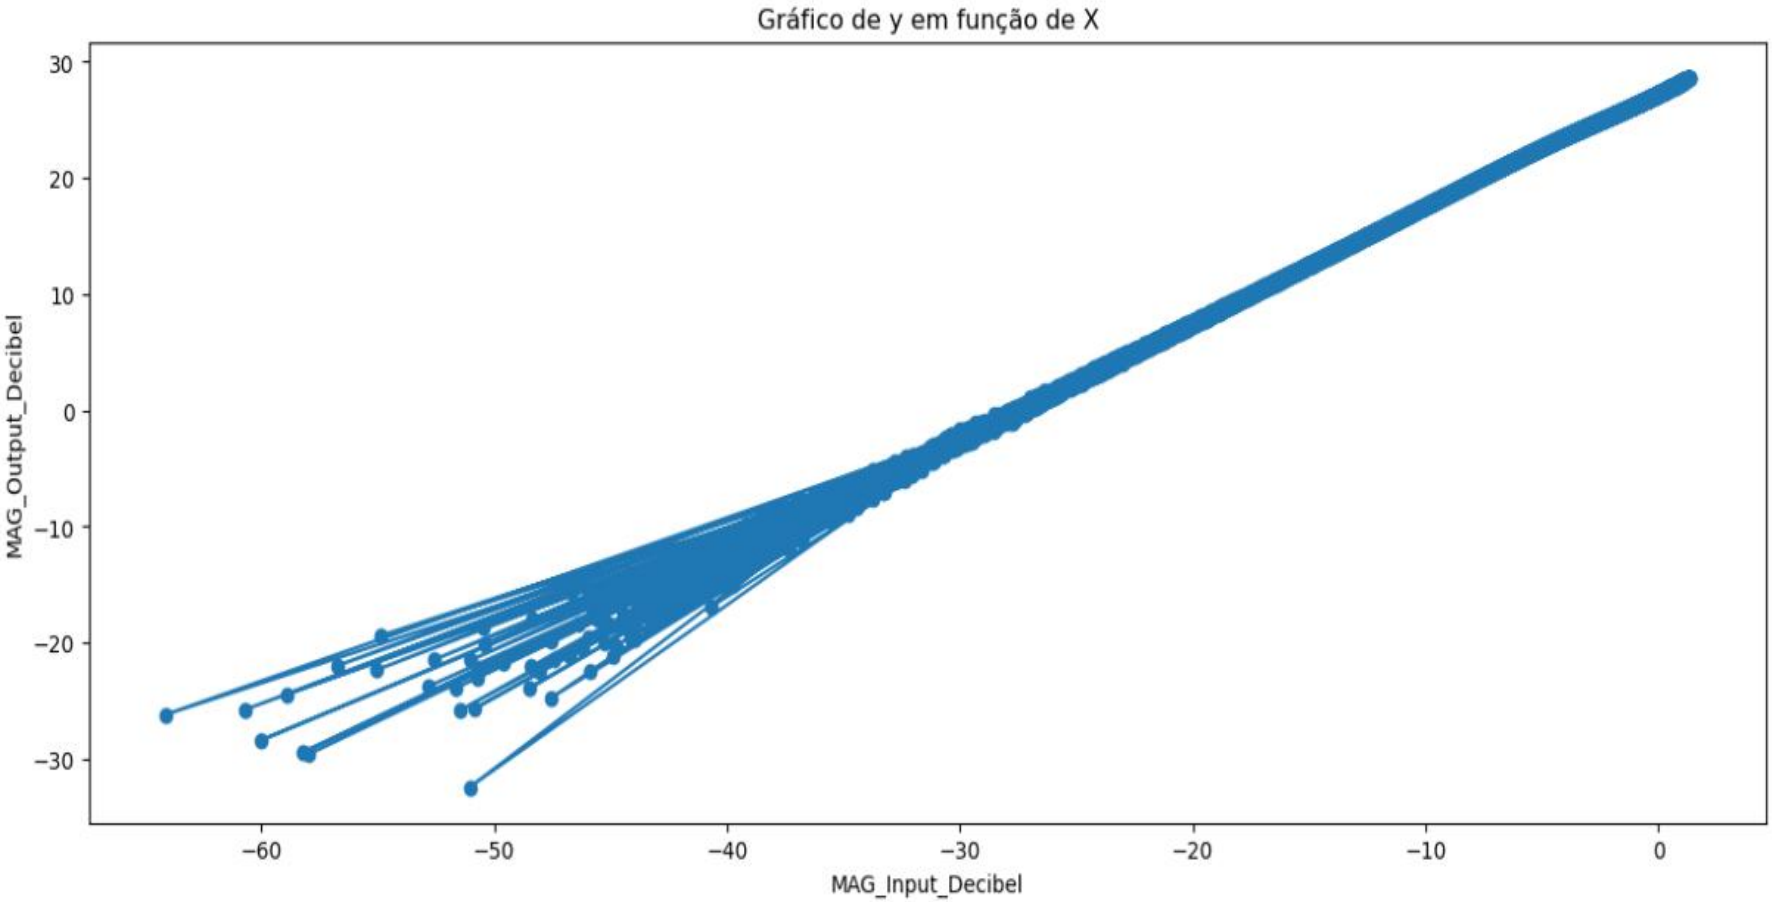

Próximos passos …

- **Estudo sobre multicolinearidade:**
  - O aumento do número de lags e a ordem de variáveis exógenas (manualmente), pode aumentar a colinearidade do modelo, o que impacta na performance;
  - Uso de correlções de **Spearman** e **Pearson** para detecção e remoção de lags;
- **Aumento da ordem dos modelos;**
- **Teste com outros modelos mais robustos;**

Fim

Muito Obrigado!